

NIPS 2017 · GOOGLE BRAIN / GOOGLE RESEARCH · ARXIV:1706.03762


Attention Is All You Need



Transformer 架构精读 · 只用注意力的序列转换模型

Vaswani · Shazeer · Parmar · Uszkoreit · Jones · Gomez · Kaiser · Polosukhin

WMT14 · EN→DE 28.4 BLEU · EN→FR 41.8 BLEU · 8× P100 · 3.5 天



串行计算，是 RNN 的天花板

逐位置串行

隐状态 $h(t)$ 依赖 $h(t-1)$ ，训练样本内部完全无法并行，序列一长就卡死。

远距离难学

卷积方案（ConvS2S / ByteNet）连接两个位置的操作数随距离线性或对数增长。

注意力只是配角

注意力早已好用，但几乎总是挂在循环网络上，串行瓶颈还在。

破局 Transformer 干脆丢掉循环和卷积：任意两个位置之间，恒定步数直接相连。

只用注意力：更快，也更好

第一个完全基于注意力的序列转换模型，训练并行度大幅提高，翻译质量反而更高。

28.4 BLEU

WMT14 英→德，超过此前所有模型和集成 2 BLEU 以上


41.8 BLEU

WMT14 英→法，单模型新纪录

3.5 天

8 块 P100 训练大模型；基础版
12 小时即在英→德超所有已发表模型


六层编码器 + 六层解码器，全靠注意力和前馈层



图：论文 Figure 1（原图）

- **编码器 ×6**：每层 = 多头自注意力 + 逐位置前馈网络
- **解码器 ×6**：多一个「编码器 - 解码器注意力」子层；自注意力带掩码，只能看已生成的前缀
- **残差 + LayerNorm**：每个子层外套 $\text{LayerNorm}(x + \text{Sublayer}(x))$ ，全模型统一 $d_{\text{model}} = 512$
- **输出**：线性层 + softmax 预测下一个词

缩放点积注意力：一次矩阵乘法算出所有权重




论文 Figure 2 左

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- **Q·K 定权重**：查询与所有键做点积，softmax 后变成对值 V 的加权求和
- **除以根号 dk**：维度大时点积会把 softmax 推进梯度极小区，缩放救回来
- **快且省**：整个序列打包成矩阵一次算完，靠的是高度优化的矩阵乘法

多头注意力：8 个子空间同时看



论文 Figure 2 右

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

- **$h = 8$ 个头并行**： Q 、 K 、 V 各自线性投影 8 次，分头做注意力再拼接
- **每头 $dk = dv = 64$** ：维度按头数摊薄，总计算量和单头全维度相当
- **为什么要多头**：单头会把不同位置的信息平均掉；多头让不同头盯不同的表示子空间

同一个机制，三处使用



编码器自注意力

Q、K、V 都来自上一层编码器输出，每个位置看全句。



解码器掩码自注意力

softmax 前把非法连接设为负无穷，每个位置只能看到之前的输出，保住自回归。



编码器 - 解码器注意力

Q 来自解码器，K、V 来自编码器输出，解码每一步都能查全部输入。

注意力之外，只剩前馈网络和位置编码

逐位置前馈网络

$$\text{FFN}(x) = \max(0, xW_1 + b_1) W_2 + b_2$$


每个位置独立过同一个两层网络，内层维度 $d_{\text{ff}} = 2048$ 。

正弦位置编码

$$PE_{(\text{pos}, 2i)} = \sin(\text{pos}/10000^{2i/d_{\text{model}}})$$

$$PE_{(\text{pos}, 2i+1)} = \cos(\text{pos}/10000^{2i/d_{\text{model}}})$$

没有循环和卷积，顺序靠加在词嵌入上的正弦波注入：每个维度一种波长（右图）。固定偏移是线性关系，便于学相对位置；学习式位置嵌入效果几乎相同。



为什么自注意力：路径最短，串行恒定

层类型	每层复杂度	串行操作	最长路径
自注意力	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
循环层	$O(n \cdot d^2)$	$O(n)$	$O(n)$
卷积层	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k n)$

要点 任意两位置一步直达（路径 $O(1)$ ），串行操作恒定；句子表示常见 $n < d$ ，自注意力连每层计算量也更低。

训练配方：8 块 P100，最多 3.5 天


数据与分词

英→德	WMT14, 450 万句对
英→法	WMT14, 3600 万句
分词	BPE 共享词表 3.7 万 / word-piece 3.2 万
批次	每批约 2.5 万源词 + 2.5 万目标词

硬件与优化

硬件	1 台机器 · 8× NVIDIA P100
时长	base 10 万步 $\approx$ 12 小时 · big 30 万步 $\approx$ 3.5 天
优化器	Adam, 学习率先热身 4000 步再按 $1/\sqrt{\text{step}}$ 衰减
正则	残差 dropout 0.1 · 标签平滑 0.1

英→德：基础版超所有前作，大杯改写纪录



WMT14 英→德 测试集 BLEU (论文 Table 2)

代价呢？

1/7

base 版训练算力约为 GNMT+RL 的 1/7 (3.3 对 23×10^{18} FLOPs)，却高出 2.7 BLEU。另一方向 big 版 41.8 BLEU，成本同样只是前 SOTA 的零头。


消融实验：多头和 dropout 最关键

配置	开发集 BLEU
base (8 头, dk=64)	25.8
单头注意力	24.9
32 头	25.4
去掉 dropout	24.6
学习式位置编码	25.7
big (更大更深)	26.4

- **头数有甜点位**：单头比最优差 0.9 BLEU；头太多（32）反而变差
- **dk 不能省**：缩小键维度伤质量，相似度计算并不简单
- **大模型 + dropout**：模型越大越好；去掉 dropout 直接掉 1.2 BLEU
- **位置编码随便选**：学习式和正弦式几乎一样（25.7 vs 25.8）

泛化到句法解析，注意力还能被看懂

F1 92.7 英语成分句法解析（WSJ）：仅 4 万句训练 F1 91.3，超过 BerkeleyParser；半监督 92.7，超过除 RNNG 外所有前作。



第 5 层的一个注意力头：「making」直接接上「more difficult」，远距离依赖被直接建模。论文 Figure 3 原图。

第一个纯注意力的序列转换模型

- **换掉循环层**：编码器 - 解码器架构的循环层，全部换成多头自注意力
- **更快 + SOTA**：训练显著快于循环 / 卷积架构；英→德、英→法双双刷新纪录
- **下一步（论文原话）**：扩展到图像、音频、视频等模态；研究局部受限注意力；让生成不那么串行

代码开源于 [tensorflow/tensor2tensor](https://github.com/tensorflow/tensor2tensor)。

后来，它改变了一切



本页为讲者延伸，不属于论文内容。

谢谢 · Q&A